

Paper2Agent 与 Paper2Any 实测

论文阅读包 科学实验与演示文稿生成

Stella 2026 年 9 月 19 日

把论文交给 AI，最后拿回一份 PPT，这条路径看起来很短。

真正做一次就会发现，中间至少有三个不同的问题：论文有没有读对，实验有没有算对，结果有没有被准确地放进 PPT。

2026 年 9 月 18 日至 19 日，我们围绕 MoleculeNet 做了一次实际测试：使用 Paper2Agent 整理论文，在 Pi GUI 中调用工具完成部分基准实验，再测试 Paper2Any 的大纲生成和 PPT 导出。

从论文材料到可检查的产物

两类工具承担不同任务 科学实验还需要单独的代码与数据




图 1 两类工具的实际职责。本次科学实验由另外编写的基准脚本执行，不能归为任一工具自动完成的能力。

结果并非全部成功。论文阅读包通过了带限制的严格验证；48 次科学运行完成并另行核验；Paper2Any 的大纲组件可用，但模型生成页面的链路失败。后来直接调用其原生导出器，才交付了一份 14 页、文字和表格可编辑的 PPTX。

这几项结果不能合并成一句“AI 已经全自动复现论文”。下面把具体过程展开。

1 两个项目的职责与接入方式

先解释一下这里的 Skill。

它不是一个新训练的模型，也不只是几句提示词。以 Pi 的机制为例，Skill 是一个可以包含 SKILL.md、脚本、参考资料和资源文件的目录。Pi 根据任务加载说明，再调用工具执行其中的流程。安装 Skill，不等于同时安装好了 Python、科学软件 and 所有模型服务。[Pi 官方 Skills 文档](#)

Paper2Agent 的官方入口分为两条路线：

- **Paper2Skill**：将 PDF 及相关材料整理成有来源、有审查记录的论文阅读包。
- **Paper2MCP**：把研究代码中已有的功能包装成可调用的 MCP 工具，并执行相应验证。

前者处理“怎样让 Agent 可靠地读取论文”，后者处理“怎样让 Agent 调用论文背后的代码”。这次实际验证的是前者，没有完成完整的代码转 MCP 流程。[Paper2Agent 官方 Skill](#)

Paper2Any 的测试重点则是内容制作：给定论文与实验材料，生成演示大纲、页面结构，再导出文档。这里有一个容易被教程写错的地方：**在本次固定版本的 Paper2Any 源码中，没有找到可直接安装进 Pi 的官方 `SKILL.md`**。实际接入方式是调用其 Python 组件，后来再调用前端原生 PPTX 导出器。因此，不能照着 Paper2Agent 的形式，凭空写出一个“安装后输入 /skill:paper2any”的教程。

对比项	Paper2Agent	本次测试的 Paper2Any
接入方式	官方 Skill 文件夹	Python 组件、原生导出器
本次输入	论文 PDF、已有审查记录	阅读材料、已核验的实验结果
主要产物	可供 Agent 检索的论文阅读包	大纲、页面结构、PPTX
本次未验证	完整 Paper2MCP	完整 Web UI、多模态制片流程

还需留意版本背景：截至本文核查时，Paper2Any 仓库已将开源代码标为 legacy snapshot；持续开发的 Nexus Office 托管产品使用另一套实现，不包含在这份仓库中。本文只评价实际检出的开源代码，不评价其商业服务。[仓库状态说明](#)

2 MoleculeNet 的测试范围与执行流程

测试对象是 Wu 等人的 *MoleculeNet: a benchmark for molecular machine learning*, 发表于 Chemical Science, PubMed 编号为 29629118。这是一篇分子机器学习基准论文, 适合检查 AIDD 工作流中的数据处理、建模和结果解释, 不是某个靶点的新药设计案例。[PubMed 论文记录](#)

我们使用的是 65 页作者稿。原文覆盖 17 个数据集, 这次选取其中三个完整数据集:

- ESOL: 1,128 条, 预测水溶解度。
- FreeSolv: 642 条, 预测水合自由能。
- Lipophilicity: 4,200 条, 预测脂溶性。

每个数据集测试均值基线、随机森林、核岭回归和图卷积模型。三个随机种子共形成 36 次运行, 再补充 12 次 ESOL 骨架划分诊断, 总计 48 次。

科学计算由 DeepChem 等实际库执行, Agent 负责调用和编排; 不是让语言模型 “猜一张结果表”。这部分也不是 Paper2Agent 或 Paper2Any 自动提供的实验能力, 而是本次另外编写并检查的基准脚本。

运行后, 核验脚本重新检查了预测值、指标、分区和来源文件。另有 26 项相关单元测试通过, 但这个数字不代表 Pi GUI 的全部功能都通过了测试。

3 Paper2Agent 的结果与审查限制

实际使用的 Paper2Skill 路径是:

实际流程依次为保存来源快照、提取 PDF、导入同源审查记录、构建阅读包、严格验证, 再用阅读包检索论文内容。

最后得到 35 个文件: 入口与正文等 Markdown 文件, 以及 30 张图片和 1 个结果表 CSV。图片保留了不适合直接转成文本的公式、图表和复杂表格。

验证结果中，几个关键字段是：

验证结果

```
{
  "status": "reviewed_with_limitations",
  "mechanical_ok": true,
  "all_sources_agent_reviewed": true,
  "issues": []
}
```

这表示阅读包的机械检查通过，来源审查已记录，但仍有明确限制。它不表示“所有表格都完美变成了结构化数据”，更不表示论文中的结论已经被实验复现。[Paper2Skill 验证状态定义](#)

限制主要有两类。

一类是内容表达。复杂表格和公式保留为图片，阅读时可以核对，但不应假设每个单元格都能直接被程序读取。一次实际解析把“ANI-1”与紧邻的上标文献编号连在了一起；类似问题如果只看提取后的文本，很容易漏掉。

另一类是审查来源。本次 Pi GUI 运行复用了主代理此前对同一份 PDF 的逐页审查记录。两份源文件的 SHA-256 一致，导入过程保留了来源；这不是 Pi 在本轮重新独立审查 65 页，也不是人工或多个独立 Agent 的交叉认证。

Windows 上还遇到一个路径问题：包内路径使用反斜杠时，校验逻辑误报。测试副本将相对路径统一为 POSIX 表示后重新验证通过。这是已记录的本地补丁，不能写成“上游原版在 Windows 上无需调整即可通过”。

4 Paper2Any 的生成失败与导出成功

第一轮从原生大纲组件开始。outline_agent 和 outline_refine_agent 顺序调用真实模型 API，分别生成和修订了 10 页大纲。两条可追踪响应的 finish_reason 都为 stop，结构检查通过，修订也确实改变了内容。

这一轮历史测试使用 DeepSeek V4.1 Flash。它是测试条件，不是对其他模型兼容性的保证。

大纲之后，继续调用原生 Paper2PPTFrontendService 的无图片页面生成路线，问题就出现了：

- 20 次 API 请求全部返回 HTTP 200。

- 10 次主题生成请求都在 1,400 token 上限处结束。
- 第 2、4、9 页也在 3,400 token 上限处结束。
- 不完整的页面 JSON 触发了默认模板替代。


上游部分返回值仍然可以带有成功标记，但本次验收将这条链路判为失败，没有继续把默认模板打包成“成功生成的报告”。

HTTP 200 只证明请求得到了响应，不能证明内容生成完整。 对这种工作流，至少还要核对结束原因、结构解析、页面是否用了默认模板，以及导出文件是否存在。

这也不能直接推导为“某个模型不行”或“Paper2Any 完全不可用”。记录能支持的判断更具体：在这次固定代码、模型和默认请求参数组合下，页面生成没有达到验收要求。

生成链路与导出链路分开验收

2026 年 9 月 18 日 原生模型生成



2026 年 9 月 19 日 主代理直接调用导出器

主代理编写 Canvas → Paper2Any 原生导出 → 14 页可编辑 PPTX

未运行前一条外部模型生成服务 导出包的失效声明另行修复并保留记录

图 2 两轮 Paper2Any 测试使用了不同路径。9 月 19 日原生导出成功，不代表 9 月 18 日失败的模型生成链路已恢复。

第二轮换了执行路径。按“不用 Pi，也不再使用 DeepSeek”的要求，由当前 Codex 主代理重新编写内容和 Canvas 页面结构，直接调用 Paper2Any 的 buildCanvasSlidesPptxBlob 导出。

这一轮没有调用 Pi，也没有另行调用 DeepSeek 或其他外部模型 API；页面内容仍由当前 Codex 主代理撰写，所以不是“不使用 AI”。它绕开了此前失败的模型页面生成服务，测试的是原生导出能力。

成品共有 14 页，包含 7 张原生可编辑表格、2 幅论文原图和逐页演讲者备注。我们从最终 PPTX 中读出 32 个结果及对照单元格，与实验汇总逐一比对；14 页均重新渲染并由主代理逐页检查。

导出也并非零问题：原始包有 13 条指向不存在、且未被引用的母版的声明。清理这些失效声明后，包结构检查通过；全部页面 XML 与原生导出仍逐页一致，没有换一套工具重新制版来冒充 Paper2Any 的结果。

因此，本轮结论是“原生导出成功，并完成了明确的打包修复”，不是“此前失败的全自动生成链路已经修好了”。更早那份独立制作的 16 页说明 PPT，也不计作 Paper2Any 原生导出成果。

FreeSolv 未重现 GraphConv 的优势

FreeSolv 测试 RMSE / kcal/mol

模型	本次实验	原论文
训练均值基线	3.963 ± 0.473	未列此基线
RF / ECFP4	2.061 ± 0.664	2.030 ± 0.220
KRR / ECFP4	1.999 ± 0.410	2.110 ± 0.070
GraphConv	2.151 ± 0.232	1.400 ± 0.160

本次 GraphConv 误差较论文均值高 53.7%
其均值也高于本次 RF 与 KRR

测试 RMSE (kcal/mol)，越低越好。本次均值 ± 样本 SD，n=3。论文：Table 8。

07 / 14

图 3 Paper2Any 原生导出的实际页面。报告保留 FreeSolv 负结果；本次协议不同于原论文，图中差值只作描述性比较。

5 真实实验结果与数据纠正

下面保留三个数据集的关键结果。指标为测试集 RMSE，越低越好；“±”是三个种子的样本标准差。不同数据集单位不同，不能跨行比较数值大小。

数据集与单位	随机森林	核岭回归	图卷积
ESOL, log10(mol/L)	1.190 ± 0.159	1.485 ± 0.119	1.046 ± 0.106
FreeSolv, kcal/mol	2.061 ± 0.664	1.999 ± 0.410	2.151 ± 0.232
Lipophilicity, logD	0.838 ± 0.011	0.835 ± 0.016	0.704 ± 0.016

三个数据集的测试集 RMSE

点为均值 误差线为样本标准差 每种模型 $n = 3$ 越低越好




图 4 从已核验 CSV 直接绘制的实测结果。各面板量程和单位不同，误差线不是置信区间。

图卷积在 ESOL 和 Lipophilicity 上的平均误差较低，但在 FreeSolv 上没有超过另外两个学习模型。这里不作统计显著性判断，也不能把三行结果概括成“深度学习全面领先”。

测试中还发现了一个比模型排名更基础的问题：使用的 DeepChem 默认 FreeSolv 压缩文件，其目标值已经做过全数据标准化。如果直接把该尺度下的误差标成 kcal/mol，就会出现约 3.845 倍的虚假改善。

我们核对了原始 SAMPL.csv 中的物理单位数据，修正读取方式，只用训练集拟合标准化参数，然后重跑受影响实验。错误批次保留，但不计入最终结果。

此外，ESOL 存在 11 条重复结构记录，三个随机种子对应的训练集与测试集结构交集分别为 2、2、0，不能宣称完全消除了结构重叠。补充的骨架划分使用同一份确定性分区，三个种子只改变模型随机性，也不是三折交叉验证。

这些限制保留在报告和 PPT 里。否则，文件越好看，越容易让读者忽略真正影响结论的条件。

6 实测结论与适用范围

验收对象	结果	不能据此推导的结论
Paper2Agent 阅读包	严格验证通过，带限制	已完整复现论文或交付 MCP
科学实验	48 次真实运行完成并核验	已还原原论文全部实验
Paper2Any 大纲与修订	通过组件级测试	后续每页都能成功生成
Paper2Any 模型页面生成	失败，保留截断与模板替代记录	HTTP 200 等于成品成功
Paper2Any 原生导出	14 页成功，附打包修复	全自动模型链路已恢复
Pi GUI 长会话刷新	测试中发现失败	长任务稳定性已全面通过

本次复现只覆盖三个数据集和四类模型，没有覆盖原论文全部 17 个数据集、全部算法、原始软件环境、精确分区及超参数搜索。它不构成药物有效性、靶点有效性或湿实验验证。

对这两个项目，我愿意给出一个范围明确的评价：Paper2Agent 的阅读包流程让来源、转换和审查结果更容易被检查；Paper2Any 的部分生成组件和原生导出器有实际可用价值，但本次模型制片链路仍有失败。

把这些阶段分开记录，比一句“从论文到 PPT 一键完成”更能帮助下一位使用者判断：自己需要哪一段能力，又必须在哪一步亲自核对结果。

测试版本：Paper2Agent 8c2d059；Paper2Any b538531；Pi 0.85.1。测试平台为 Windows。本文依据 2026 年 9 月 18—19 日保存的运行、接口与文件验收记录；未完成 macOS、完整 Paper2MCP、Paper2Any 全量多模态工作流或 Microsoft PowerPoint 桌面应用验收。